Aprendizagem de Máquina

Aula 03 – Preparação e Análise de Dados com Python

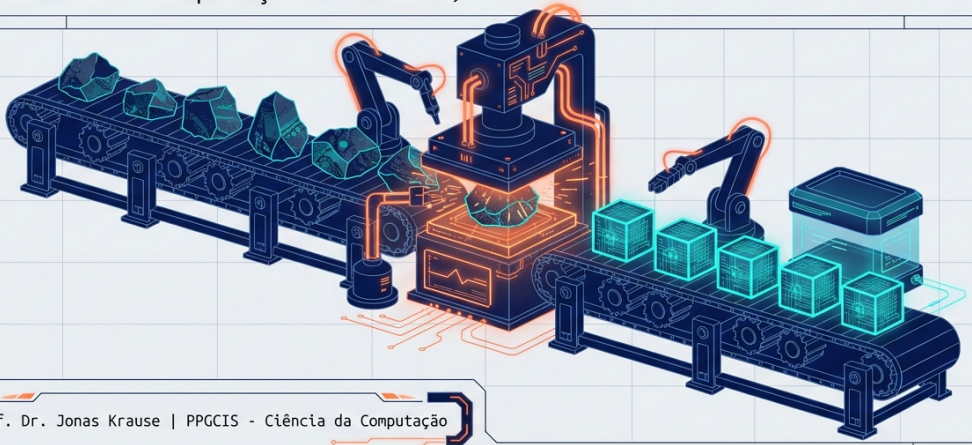
Prof. Dr. Jonas Krause

PUCPR - PPGCIS - Ciência da Computação

20 de agosto de 2026

A Engenharia dos Dados

Construindo a linha de montagem para modelos de Machine Learning.
(Aula 03 – Preparação e Análise)



Prof. Dr. Jonas Krause | PPGCIS - Ciência da Computação

Gemini Notebook

Aula 03 – onde estamos?

Semanas 3–4

Preparação e análise de dados. Laboratórios em Python.

- Nas aulas anteriores: problema, features, target, treino e teste.
- Agora: aprender a **inspecionar, limpar, transformar e preparar** os dados.
- O objetivo não é ainda comparar muitos algoritmos.
- O objetivo é construir um dataset confiável para os modelos.

Ideia-chave

Um modelo aprende apenas a partir dos dados que recebe.

Exercícios das Aulas 01 e 02 – entregas por equipe

Eq. 1 (1 e 2): Emily Pontes; Erick Maestri; Julia Kociolek; Sofia

Eq. 2 (1): Adryan Costa Silva; Hassan Ali El Gazouini; Hussein Ali El Gazouini

Eq. 3 (1 e 2): Renan da Silva Oliveira Andrade; Renan Americo Herculano; Lucas da Costa Paula; Guilherme Arcanjo de Morais

Eq. 4 (1): Larissa Alves da Silva

Eq. 5 (1 e 2): Gustavo Klinfuss da Silva

Eq. 6 (1 e 2): Alisson Daledone Hass de Lima; Geandro Marques da Silva; Juliano Teles Tolomini Biasotto

Eq. 7 (1 e 2): Artur Moretti Zimmermann; Bruno Navarro Ivaitiuk; Gustavo Lisboa; Joaquim dos Anjos Faraco; Vinicius Souza Penhorato

Eq. 8 (1): Alana da Conceição Queiroz; Leticia Maria Maia de Andrade Vieira; Thomas Manussadjian Steinhausser

Eq. 9 (1): Emmanuel Antonietti Ribeiro dos Santos; Enzo Wasko Amorim; Juliano Cesar Enns Miranda Marcos; Pedro Joslin Cavalli; Vinícius Paraíso Dias

Eq. 10 (1 e 2): Ricardo Lucas Kucek; Lucas Ferraz dos Santos; Riscala Miguel Fadel Neto; Pedro Senes Velloso Ribeiro

Eq. 11 (1): Ana Sales

Eq. 12 (1 e 2): Murilo Zimerman Fortaleza

Eq. 13 (1 e 2): André Vinícius; Felipe Willian; Gabriel Calado; Luis Gustavo

Eq. 14 (1 e 2): Alan Filipe; Antonio Bernardo; Gustavo Lona; Pedro Henrique

Eq. 15 (1 e 2): Brenda Barbosa; Eros dos Santos; Natalia Trevisol

Eq. 16 (1 e 2): Victor Esmaniotto

Eq. 17 (1 e 2): Ana Carolina Afonso Meiado; Ana Carolina Curi de Sales; Anna Bosquillia Navarro

Da Aula 02 para a Aula 03

Já sabemos perguntar

- Qual é o problema?
- Quais são as features?
- Qual é o target?
- É supervisionado?
- O target é contínuo ou categórico?

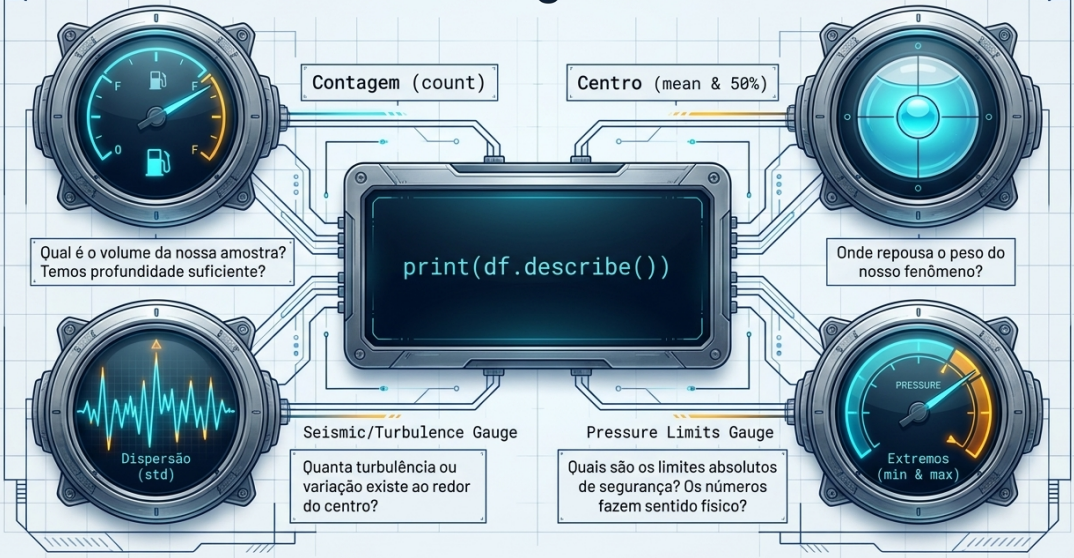
Agora precisamos perguntar

- Os dados estão corretos?
- Há valores ausentes?
- Há outliers?
- As escalas são comparáveis?
- Existem variáveis categóricas?

Roteiro da aula

1. Carregamento e inspeção
2. Estatística descritiva
3. Visualização dos dados
4. Dados ausentes
5. Duplicatas e inconsistências
6. Outliers
7. Variáveis categóricas
8. Normalização e padronização
9. Treino e teste sem vazamento
10. Exercício integrado

O Painel de Diagnóstico Inicial

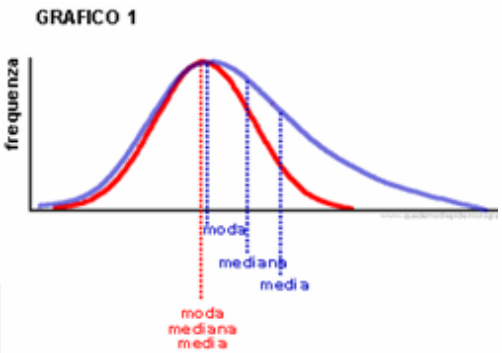


Gemini Notebook

Estatística descritiva

Para variáveis numéricas, observe:

- média;
- mediana;
- mínimo e máximo;
- desvio padrão;
- quartis;
- amplitude.

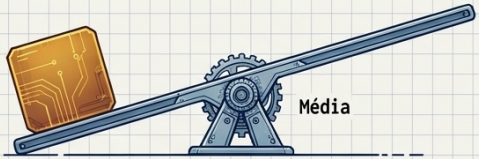


Pergunta importante

Os números encontrados fazem sentido no contexto do problema?

Medindo a Matéria-Prima: Centro e Dispersão

Onde está o centro?

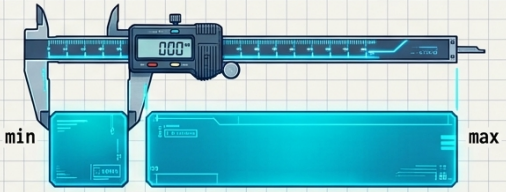


O centro de gravidade. Altamente sensível a pesos extremos (outliers).

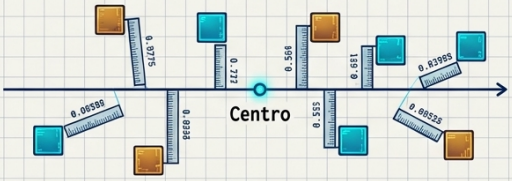


O ponto de corte exato onde metade dos dados fica de cada lado. Imune a anomalias extremas. (Dica de diagnóstico: se a Média a Média for muito diferente da Mediana, há assimetria grave).

Qual é o tamanho da dispersão?



Amplitude: A distância total entre o min e o max. A largura bruta da calha por onde o dado passa.



Desvio Padrão (std): A régua da variabilidade. Indica, em média, o quanto os pontos individuais se afastam do centro.

Gemini Notebook

Exercício em Python 1 – inspeção e estatística

Código-base

```
import pandas as pd

dados = {
 "idade":[21,35,42,29,51,35,None,120],
 "salario":[2500,4200,6100,3300,7200,4200,3900,4500],
 "cidade":["Curitiba","Curitiba","Londrina","Maringa",
           "curitiba","Curitiba","Londrina","Maringa"],
 "comprou":[0,1,1,0,1,1,0,1]
}
df = pd.DataFrame(dados)

print(df.head())
print(df.shape)
print(df.dtypes)
print(df.info())
print(df.describe())
print(df["idade"].mean())
print(df["idade"].median())
```

Atividades

1. Identifique features e target.
2. Informe linhas e colunas.
3. Localize valores ausentes.
4. Compare média e mediana da idade.
5. Identifique um valor suspeito.
6. Repita a análise para `salario`.

A Lupa da EDA: Inspeção Inicial

Regra prática de engenharia de dados: Não comece pelo model.fit(). Comece pelo dataset. A Análise Exploratória (EDA) é o diagnóstico estrutural antes de qualquer intervenção.

Dimensão (df.shape)

```
df.shape
```

Qual é o volume da amostra?
Temos profundidade suficiente?

Anatomia (df.info())

```
df.info()
```

Os tipos de dados (Dtypes) correspondem à realidade?
Temos números lidos como texto?

Distribuição (df.describe())

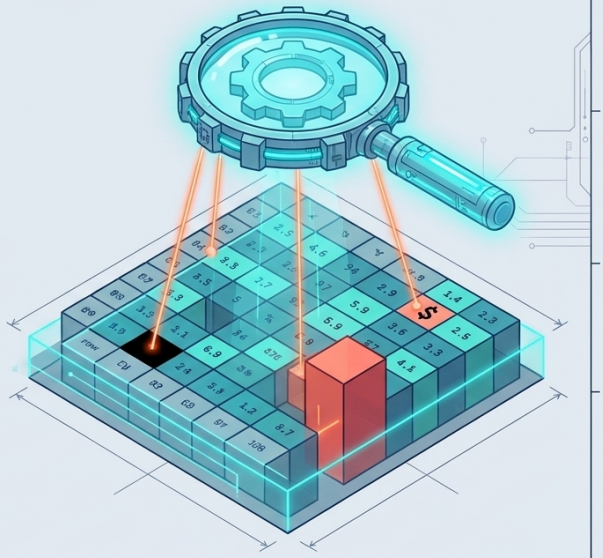
```
df.describe()
```

As médias, mínimos e máximos fazem sentido físico?
Existem assimetrias graves?

Vazios (df.isna().sum())

```
df.isna().sum()
```

Qual é o percentual de dados estruturalmente ausentes?



Gemini Notebook

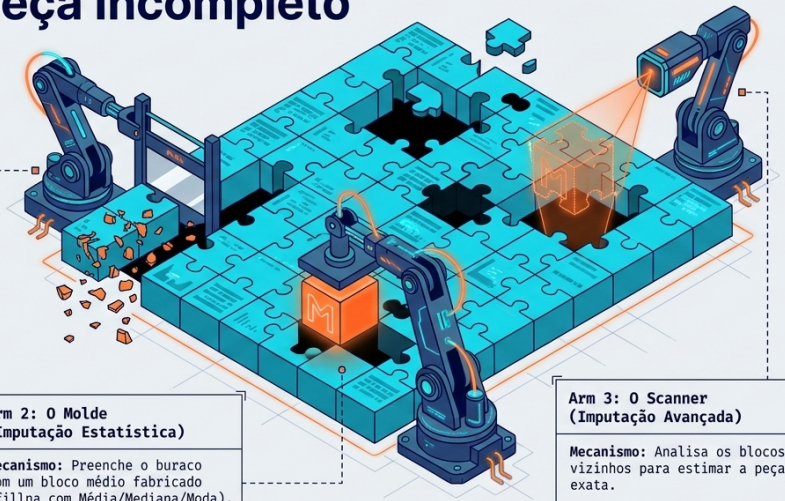
Por que visualizar os dados?

Visualizações ajudam a perceber:

- distribuições;
- assimetrias;
- concentrações;
- relações entre variáveis;
- valores extremos;
- diferenças entre grupos.

O Quebra-cabeça Incompleto

Valores ausentes (NaN, None, -999) quebram a continuidade matemática exigida pelos algoritmos. Não existe regra universal; a solução depende da densidade do erro.



Arm 1: A Guilhotina (Remoção)

Mecanismo: Deleta a linha ou coluna inteira (dropna).

Uso: Quando o dado ausente é raro ou a coluna é irrelevante.

Arm 2: O Molde (Imputação Estatística)

Mecanismo: Preenche o buraco com um bloco médio fabricado (fillna com Média/Mediana/Moda).

Uso: Preserva o volume de dados, mas reduz a variância natural.

Arm 3: O Scanner (Imputação Avançada)

Mecanismo: Analisa os blocos vizinhos para estimar a peça exata.

Uso: Algoritmos que deduzem o valor baseado no contexto das outras variáveis.

Gemini Notebook

Dados ausentes

Valores ausentes podem aparecer como:

- `NaN`;
- `None`;
- célula vazia;
- códigos como -999;
- texto como “não informado”.

Primeiro: **descobrir quanto está faltando**.

O que fazer com valores ausentes?

Possibilidades:

- remover linhas;
- remover colunas;
- preencher com média;
- preencher com mediana;
- preencher com moda;
- usar imputadores mais sofisticados.

Não existe solução universal

A decisão depende da variável e do contexto.

Exercício em Python 2 – EDA e dados ausentes

Código-base

```
import matplotlib.pyplot as plt

df["salario"].hist(bins=6)
plt.show()

plt.boxplot(df["salario"].dropna())
plt.show()

plt.scatter(df["idade"], df["salario"])
plt.show()

print(df[["idade","salario"]].corr())
print(df.isna().sum())
print(df.isna().mean()*100)

df_media = df.copy()
df_media["idade"] = df_media["idade"].fillna(
    df_media["idade"].mean()
)
```

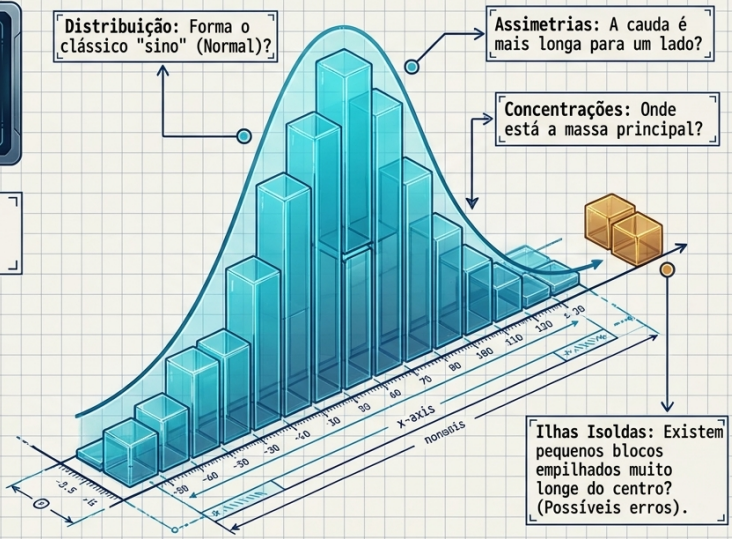
Atividades

1. Interprete histograma e boxplot.
2. Analise idade $\times$ salário.
3. Calcule a correlação.
4. Recalcule sem idade 120.
5. Calcule ausentes em quantidade e %.
6. Compare imputação por média e mediana.

A Forma Física dos Dados

```
df['variavel'].hist(bins=10)
```

O Conceito: O Histograma agrupa nossos números em "caixas" (bins) e as empilha.



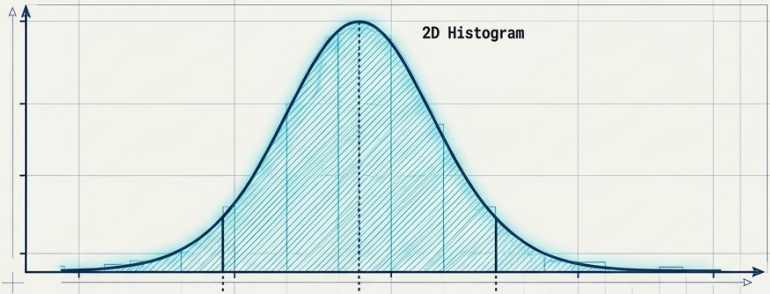
Gemini Notebook

A Anatomia Espacial do Boxplot

Código:

```
plt.boxplot(df['variavel'].dropna())
```

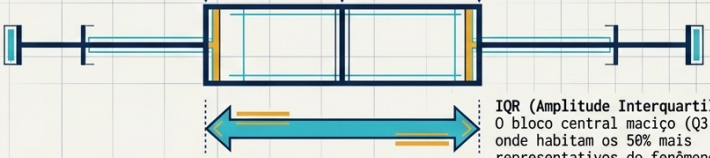
A Tradução:
O boxplot é a vista superior do histograma, achatada em um diagrama estrutural.



Q1 (25%):
A fronteira onde começa a massa principal.

Mediana (Q2 / 50%):
O eixo central da caixa.

Q3 (75%):
A fronteira onde termina a massa principal.



IQR (Amplitude Interquartil):
O bloco central maciço (Q3 - Q1) onde habitam os 50% mais representativos do fenômeno.

Gemini Notebook

Duplicatas e inconsistências

Problemas comuns:

- mesma linha repetida;
- categorias escritas de formas diferentes;
- espaços extras;
- letras maiúsculas/minúsculas;
- valores impossíveis;
- unidades diferentes.

O Radar de Outliers

Extremos numéricos deformam a superfície de aprendizado de algoritmos sensíveis. O radar detecta anomalias, mas o engenheiro decide o destino.

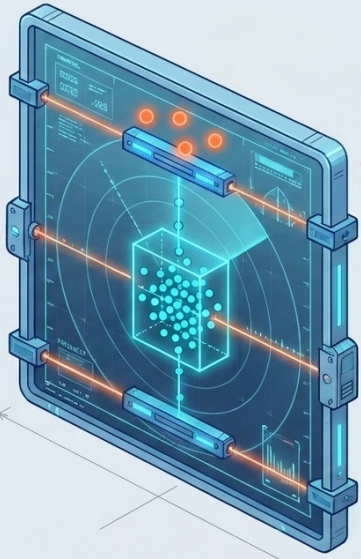
A Mecânica do Limite (A Regra do IQR):

Amplitude Interquartil (IQR): Q3 − Q1 (A faixa onde habitam 50% dos dados centrais).

Barreira Inferior: Q1 − 1.5 × IQR

Barreira Superior: Q3 + 1.5 × IQR





Gemini Notebook

Outliers

Um outlier é uma observação muito diferente do padrão predominante.
Pode ser:

- erro;
- digitação incorreta;
- falha de sensor;
- evento raro real;
- comportamento importante do fenômeno.

Regra do IQR

$$IQR = Q_3 - Q_1$$

Limite inferior:

$$Q_1 - 1.5IQR$$

Limite superior:

$$Q_3 + 1.5IQR$$

O Radar de Outliers e a Regra do IQR

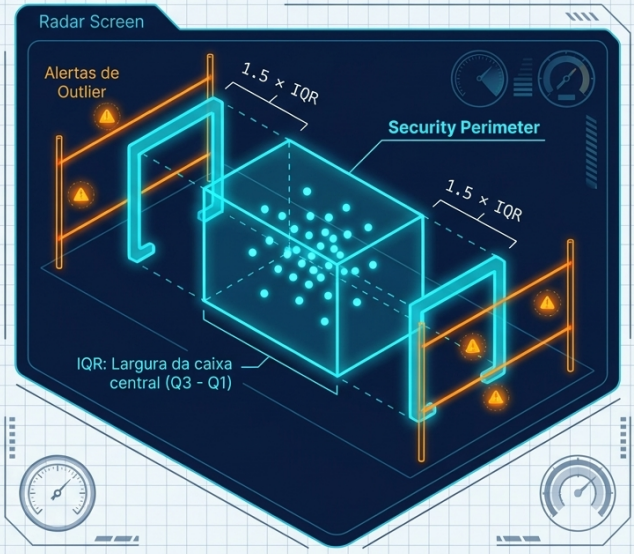
O Problema:
Extremos numéricos deformam a superfície de aprendizado de algoritmos sensíveis. Precisamos de um radar para anomalias.

Decisão do Engenheiro

Um ponto detectado pelo radar (em laranja)

→ Pode ser:

- Erro de medição/digitação (deve ser removido).
- Evento raro verdadeiro (deve ser mantido).



A Mecânica do Limite (Barreiras de Segurança):

```
Barreira Inferior: Q1 – 1.5 * IQR
Barreira Superior: Q3 + 1.5 * IQR
```

Gemini Notebook

Variáveis categóricas

Modelos trabalham principalmente com representações numéricas.
Exemplo:

$$\{\text{Curitiba}, \text{Londrina}, \text{Maringá}\}$$

Não devemos criar uma ordem artificial sem justificativa.

O Tradutor de Categorias

Algoritmos não sabem ler. Se atribuirmos números arbitrários a categorias de texto (ex: Curitiba = 1, Londrina = 2, Maringá = 3), o modelo assumirá falsamente que Maringá 'vale mais' ou é 'maior' que Curitiba.

A Solução: One-Hot Encoding

Cada categoria distinta é traduzida para uma coluna binária (0 ou 1) totalmente independente, eliminando qualquer hierarquia matemática oculta.



Input (1 Coluna)	Output (3 Colunas Booleanas)	Output (3 Colunas Booleanas)
Cidade: [Curitiba],	→ Curitiba: 1, 0, 0	→ Curitiba: 1, 0, 0
[Londrina],	→ Londrina: 0, 1, 0	→ Londrina: 0, 1, 0
[Maringá]	→ Maringá: 0, 0, 1	→ Maringá: 0, 0, 1

Gemini Notebook

Exercício em Python 3 – limpeza, outliers e categorias

Código-base

```
print(df.duplicated().sum())
print(df["cidade"].value_counts())

df["cidade"] = (
    df["cidade"].str.strip().str.lower()
)

q1 = df["idade"].quantile(0.25)
q3 = df["idade"].quantile(0.75)
iqr = q3 - q1
li = q1 - 1.5*iqr
ls = q3 + 1.5*iqr

outliers = df[
 (df["idade"] < li) | (df["idade"] > ls)
]
print(outliers)

df2 = pd.get_dummies(
    df, columns=["cidade"], dtype=int
)
```

Atividades

1. Verifique duplicatas.
2. Padronize `cidade`.
3. Compare categorias antes/depois.
4. Calcule os limites do IQR.
5. Liste os outliers.
6. Discuta o valor 120.
7. Observe as colunas do One-Hot.

Por que a escala importa?

Considere:

idade : 20 a 60

salário : 2000 a 8000

Para alguns algoritmos, a variável com maior magnitude pode dominar cálculos de distância ou otimização.

O Perigo das Escalas Desiguais



⚠ O Ponto Cego do Algoritmo

Para modelos baseados em cálculo de distância (como KNN ou SVM), variáveis com magnitude numericamente gigante esmagam a influência de variáveis menores.

⚠ O Efeito Colateral

O modelo assume falsamente que "Salário" é 100 vezes mais importante que "Idade" para o fenômeno, simplesmente porque os números contêm mais zeros.

A Solução Necessária

A escala matemática deve ser equalizada antes do treinamento.

Gemini Notebook

Normalização Min–Max

$$x' = \frac{x - x_{\text{min}}}{x_{\text{max}} - x_{\text{min}}}$$

Normalmente:

$$0 \leq x' \leq 1$$

Interpretação

O menor valor vira 0 e o maior vira 1.

Padronização

$$z = \frac{x - \mu}{\sigma}$$

Após a transformação:

$$\mu \approx 0$$

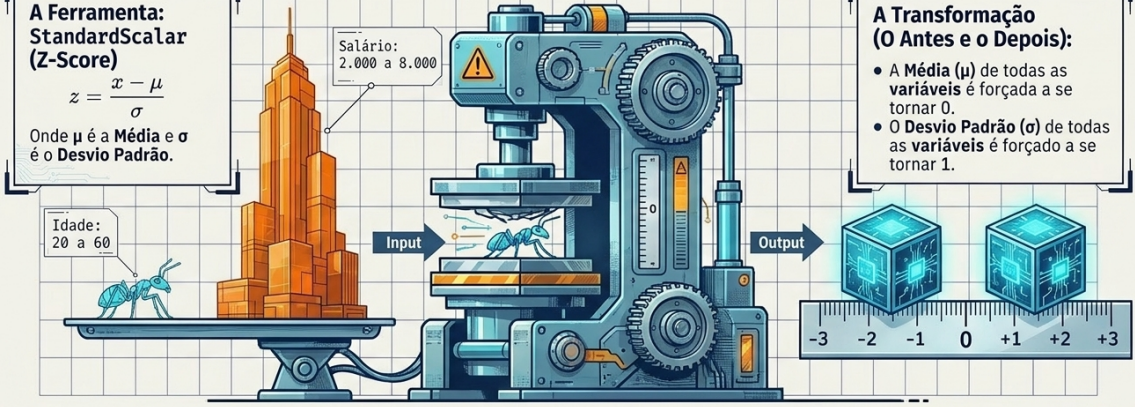
$$\sigma \approx 1$$

A Prensa da Padronização Matemática

A Ferramenta: StandardScalar (Z-Score)

$$z = \frac{x - \mu}{\sigma}$$

Onde **μ** é a **Média** e **σ** é o **Desvio Padrão**.



A Transformação (O Antes e o Depois):

- A **Média (μ)** de todas as **variáveis** é forçada a se tornar 0.
- O **Desvio Padrão (σ)** de todas as **variáveis** é forçado a se tornar 1.

O Resultado: A "Idade" e o "Salário" agora falam exatamente o mesmo idioma numérico, permitindo que o algoritmo compare sua verdadeira importância sem distorções.

Gemini Notebook

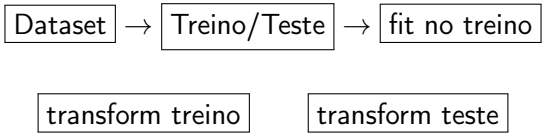
Data leakage

Erro comum:

$$\text{escalonar tudo} \rightarrow \text{dividir treino/teste}$$

O scaler aprende informações do conjunto que deveria permanecer desconhecido.

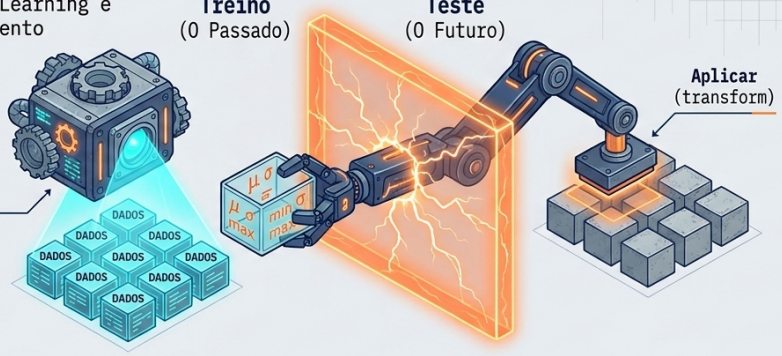
Ordem correta



O Muro do Futuro (Data Leakage)

O pecado capital do Machine Learning é permitir que o pré-processamento espie os dados de teste.

O conjunto de teste representa o futuro desconhecido.



A Engenharia da Prevenção:

1. Separar Primeiro

Divida o dataset (train_test_split) antes de qualquer escalonamento ou imputação global.

2. Aprender no Treino (fit)

O Scaler extrai os parâmetros (μ, σ, min, max) exclusivamente dos dados de Treino.

3. Aplicar em Ambos (transform)

Aplique exatamente os mesmos parâmetros aprendidos no Treino para modificar os dados de Teste. O modelo nunca aprende a escala do Teste.

Gemini Notebook

Exercício em Python 4 – escala, leakage e modelo

Código-base

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score

X = df[["idade","salario"]]
y = df["comprou"]

X_train,X_test,y_train,y_test = train_test_split(
    X,y,test_size=0.25,random_state=42
)

scaler = StandardScaler()
X_train_s = scaler.fit_transform(X_train)
X_test_s = scaler.transform(X_test)

modelo = LogisticRegression()
modelo.fit(X_train_s,y_train)
pred = modelo.predict(X_test_s)

print(accuracy_score(y_test,pred))
```

Atividades

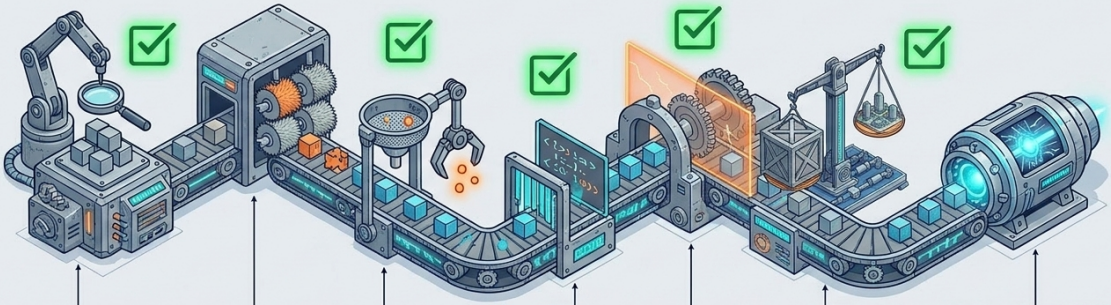
1. Repita com MinMaxScaler.
2. Compare as escalas.
3. Explique `fit_transform` no treino.
4. Explique `transform` no teste.
5. Mostre onde ocorreria leakage.
6. Treine com e sem escala.
7. Compare a acurácia.

Checklist antes do modelo

- ☐ Conheço as colunas?
- ☐ Defini corretamente o target?
- ☐ Verifiquei tipos?
- ☐ Verifiquei ausentes?
- ☐ Verifiquei duplicatas?
- ☐ Analisei outliers?
- ☐ Tratei categorias?
- ☐ Avaliei a escala?
- ☐ Separei treino e teste antes do fit?
- ☐ Evitei vazamento de dados?

Checklist da Linha de Montagem

O fluxo de pré-processamento é reprodutível e estrito. Nenhuma matriz entra no model.fit() sem passar por todas as estações de inspeção.



1. **Estrutura & EDA:** Entendi o significado das colunas e separei o Target (y)?

2. **Inconsistências:** Tratei dados ausentes (NaN) e removi duplicatas?

3. **Filtro de Ruído:** Analisei e decidi o destino dos Outliers?

4. **Tradução (OHE):** Converti variáveis categóricas de texto em matrizes binárias?

5. **A Grande Divisão:** Separei Treino e Teste garantindo a prevenção de vazamento (Leakage)?

6. **Escalonamento:** Apliquei MinMaxScaler ou StandardScaler apenas baseando-me no Treino?

Status: Verde.
O Dataset está pronto para o motor matemático.

Gemini Notebook

Resumo da Aula 03

Hoje fizemos, em Python:

- leitura e inspeção;
- estatística descritiva;
- histogramas, boxplots e scatter plots;
- correlação;
- dados ausentes;
- duplicatas e inconsistências;
- outliers com IQR;
- One-Hot Encoding;
- MinMaxScaler;
- StandardScaler;
- treino/teste sem vazamento;
- primeiro modelo após o pré-processamento.

Próxima aula

Continuação

Organização do pré-processamento e construção de fluxos reproduzíveis.

- consolidar preparação;
- automatizar transformações;
- preparar os dados para modelos supervisionados;
- iniciar comparação de modelos.

Perguntas?

Aprendizagem de Máquina – Aula 03