

Relatório de revisão e proposta de progressão científica

Modelo CBA: fundamentos, extensões e próximos passos

Projeto PIBIC – João Pedro Gadens Mosson

RECOMENDAÇÃO: O projeto deve reproduzir um CBA fiel e auditável, medir o efeito da discretização e dos limiares e, como contribuição principal, testar uma seleção/ordenação de regras que combine poder preditivo, interesse e simplicidade. O tratamento explícito de desbalanceamento fica como segunda etapa, aplicado apenas se o domínio/dataset do PIBIC justificar.

Contents

1	Resumo executivo	2
2	Fundamentos necessários	2
2.1	Regras de associação e regras de classe	2
2.2	Construção do classificador	3
2.3	O papel da discretização	3
3	Resumo crítico dos textos	3
3.1	Liu, Hsu e Ma (1998): integração entre classificação e associação	3
3.2	Wang, Tay e Liu (1998): intervalos numéricos guiados por interessância	3
3.3	Molina e Prados-Suárez (2023): complexidade e interessância	4
3.4	Ndour, Diop e Dossou Gbété (2015): classificação desbalanceada	4
3.5	Han, Kamber e Pei (2012): enquadramento e alternativas	5
4	Síntese comparativa	5
5	Próximo passo recomendado	5
5.1	Pergunta de pesquisa	5
5.2	Hipóteses	6
5.3	Extensão proposta: CBA-QS	6
6	Plano de progressão do PIBIC	6
6.1	Fase 1 – domínio conceitual e baseline (meses 1–2)	6
6.2	Fase 2 – estudo controlado do CBA (meses 3–4)	7
6.3	Fase 3 – desenvolvimento do CBA-QS (meses 5–7)	7
6.4	Fase 4 – avaliação comparativa (meses 8–10)	7
6.5	Fase 5 – consolidação (meses 11–12)	8
7	Protocolo experimental recomendado	8
7.1	Bases e recorte inicial	8
7.2	Métricas	8
7.3	Validação e estatística	8
7.4	Critério de sucesso	9
8	Riscos e controles	9
9	Entregáveis esperados	9
10	Conclusão	9

1 Resumo executivo

O CBA transforma regras de associação em um classificador interpretável. Em vez de minerar associações com qualquer consequente, ele restringe o consequente à classe e produz regras do tipo

$$X \Rightarrow c,$$

em que X é uma conjunção de condições sobre atributos e c é um rótulo de classe. O artigo fundador de Liu, Hsu e Ma introduz as regras de associação de classe, o gerador CBA-RG e o construtor CBA-CB. O método apresentou erro médio menor que o C4.5rules nos 26 conjuntos avaliados, mas também revelou seu principal gargalo: a geração combinatória de regras [1].

Os demais textos mostram quatro direções complementares. Wang, Tay e Liu tratam atributos numéricos por fusão de intervalos guiada pela interessância das regras [2]. Molina e Prados-Suárez reduzem a busca ao considerar itemsets não apenas frequentes, mas interessantes e regras simples [3]. Ndour, Diop e Dossou Gbété exploram padrões como classificadores fracos para eventos raros e enfatizam sensibilidade, especificidade e risco relativo [4]. Han, Kamber e Pei situam o CBA em uma família maior, comparando-o a CMAR, CPAR e classificadores baseados em padrões discriminativos [5].

Para o PIBIC, recomenda-se uma progressão em três níveis: (i) reproduzir um CBA de referência e validar cada etapa; (ii) conduzir um estudo controlado de discretização, suporte, confiança e poda; e (iii) propor um **CBA guiado por qualidade e simplicidade**, no qual as regras sejam selecionadas por uma função multicritério que considere desempenho preditivo, interessância e complexidade. Essa extensão é suficientemente científica para produzir comparação e análise, mas permanece compatível com a fase inicial do projeto.

2 Fundamentos necessários

2.1 Regras de associação e regras de classe

Para uma regra $X \Rightarrow c$, o suporte e a confiança podem ser definidos por

$$\text{sup}(X \Rightarrow c) = \frac{|\{t \in D : X \cup \{c\} \subseteq t\}|}{|D|}, \quad (1)$$

$$\text{conf}(X \Rightarrow c) = \frac{\text{sup}(X \cup \{c\})}{\text{sup}(X)}. \quad (2)$$

O suporte mede a cobertura conjunta; a confiança estima a proporção de registros cobertos por X que pertencem a c . No CBA, candidatos são gerados por uma adaptação do Apriori, filtrados por suporte e confiança e ordenados, originalmente, por confiança, suporte e precedência de geração [1].

Essas medidas não são suficientes isoladamente. Uma regra pode ter alta confiança apenas porque a classe consequente é muito frequente. Medidas como *lift*, *leverage*, fator de certeza, risco relativo ou ganho de informação ajudam a distinguir associação genuína de um efeito da prevalência. O livro de Han, Kamber e Pei também alerta que frequência não equivale necessariamente a poder discriminativo [5].

2.2 Construção do classificador

O CBA clássico tem duas partes. O CBA-RG gera as CARs; o CBA-CB ordena e seleciona regras que cobrem corretamente exemplos de treinamento. O classificador final funciona como uma lista de decisão: a primeira regra compatível determina a classe; se nenhuma regra se aplica, usa-se uma classe padrão. Essa estrutura torna a decisão inspecionável, mas cria dependência forte da ordenação das regras.

2.3 O papel da discretização

Como as condições das regras são pares atributo–valor, atributos contínuos precisam ser discretizados. Intervalos estreitos têm pouco suporte, enquanto intervalos largos podem misturar comportamentos diferentes e reduzir a confiança. Wang, Tay e Liu formulam esse conflito como um problema de fusão de intervalos adjacentes guiada pela interessância global das regras [2]. Portanto, discretização não deve ser tratada como detalhe de pré-processamento: ela altera o espaço de regras e, consequentemente, o classificador.

3 Resumo crítico dos textos

3.1 Liu, Hsu e Ma (1998): integração entre classificação e associação

O artigo *Integrating Classification and Association Rule Mining* estabelece o paradigma da classificação associativa. Sua contribuição central é restringir as regras ao consequente de classe, minerar CARs de forma sistemática e construir, a partir delas, um classificador ordenado. O CBA-RG adapta o Apriori; o CBA-CB escolhe um subconjunto das regras e adiciona uma classe padrão.

Nos 26 conjuntos da UCI, com confiança mínima de 50% e, em geral, suporte mínimo de 1%, o erro médio do CBA ficou entre 15,6% e 15,8%, contra 16,7% do C4.5rules sem discretização. A poda reduziu o número médio de CARs de aproximadamente 35.140 para 2.377, com pouca alteração da acurácia. Entretanto, 16 dos 26 conjuntos atingiram o limite de 80 mil candidatos em memória. O próprio experimento, portanto, demonstra simultaneamente o potencial preditivo e a explosão do espaço de busca [1].

Importância para o projeto: este trabalho deve ser a especificação conceitual do baseline. A reprodução precisa verificar geração, precedência, cobertura, poda e classe padrão, e não apenas chamar uma biblioteca de regras de associação.

Limitações: uso de bases e comparadores hoje restritos; forte sensibilidade aos limiares; dependência da discretização; geração de muitas regras; avaliação centrada em erro médio, sem análise moderna de estabilidade, calibração ou custo de interpretabilidade.

3.2 Wang, Tay e Liu (1998): intervalos numéricos guiados por interessância

O trabalho *Interestingness-Based Interval Merger for Numeric Association Rules* parte de intervalos elementares e funde intervalos adjacentes de baixo para cima. A decisão de fusão procura preservar informação e aumentar a interessância do conjunto de regras. Os autores destacam que discretizar cada atributo isoladamente pode ignorar interações entre variáveis. A implementação usa uma modificação de B-tree e apresenta complexidade de entrada/saída $O(kN)$, em que k é o número de atributos e N o número de registros [2].

Importância para o projeto: mostra que a discretização deve ser incluída nos experimentos do CBA. Comparar uma discretização simples, uma supervisionada e uma orientada à qualidade das regras pode produzir resultados mais informativos que apenas ajustar suporte e confiança.

Limitações: trabalho anterior às práticas atuais de validação; objetivo de interessância dependente de escolhas do usuário; o custo total da mineração posterior ainda pode ser elevado; não resolve sozinho a seleção final das regras classificadoras.

3.3 Molina e Prados-Suárez (2023): complexidade e interessância

O artigo propõe uma variação do COGiARE para controlar a quantidade e a complexidade das regras desde a geração. Em lugar de gerar todo o conjunto de itemsets frequentes e selecionar regras somente ao final, o procedimento cresce iterativamente o tamanho dos itemsets e interrompe quando não há melhora. Além do suporte, introduz um limiar de interessância; a qualidade das regras utiliza fator de certeza. Em uma base de pacientes com COVID-19, a inclusão de itemsets interessantes melhorou a precisão sem grande aumento no número de itemsets e regras [3].

O próprio artigo reconhece que a evidência ainda é limitada: a avaliação foi concentrada em uma aplicação, e os autores recomendam comparação com métodos conhecidos e bases mais complexas.

Importância para o projeto: fornece a inspiração mais direta para uma contribuição de PIBIC: selecionar regras considerando simultaneamente qualidade preditiva e simplicidade, e medir explicitamente o compromisso entre desempenho e interpretabilidade.

Limitações: validação empírica estreita; não demonstra superioridade geral; os resultados dependem dos limiares e da medida de interesse; falta uma comparação estatística ampla.

3.4 Ndour, Diop e Dossou Gbété (2015): classificação desbalanceada

O artigo formula padrões de associação como classificadores fracos e os combina em um classificador binário baseado em padrões (PBBC). O foco é a classe rara. Os padrões relevantes são selecionados com medidas como risco relativo, taxa de verdadeiros positivos e taxa de verdadeiros negativos. Nos experimentos relatados, o método foi competitivo com técnicas como SMOTE e ROSE e, em bases grandes com prevalência da classe-alvo inferior a 15%, mostrou vantagem em cenários nos quais a distribuição da classe diferia entre treino e teste [4].

A abordagem mantém a identificação explícita de interações entre atributos e pode ser representada por uma estrutura de regras, evitando uma decisão inteiramente opaca. Em contrapartida, exige variáveis categóricas ou discretizadas e uma quantidade de dados suficiente para estimar padrões raros com estabilidade.

Importância para o projeto: indica como avaliar o CBA quando houver desbalanceamento. Acurácia isolada deve ser substituída ou acompanhada por sensibilidade, especificidade, precisão, F_1 , balanced accuracy, MCC e PR-AUC.

Limitações: é uma extensão especializada para classificação binária rara, não um substituto universal do CBA; o pré-processamento categórico é obrigatório; padrões com baixa frequência podem ter estimativas instáveis.

3.5 Han, Kamber e Pei (2012): enquadramento e alternativas

O capítulo do livro organiza a classificação por padrões frequentes. O CBA utiliza a regra compatível de maior precedência. O CMAR combina múltiplas regras, usa estruturas do tipo FP-tree e poda por confiança, correlação e cobertura; os resultados citados no livro indicam pequena vantagem média de acurácia e melhor eficiência sobre o CBA. O CPAR gera menos regras por uma estratégia inspirada no FOIL e utiliza as melhores k regras por classe. O texto ainda separa mineração de padrões frequentes de mineração de padrões discriminativos: nem todo padrão frequente é útil para classificação, e muitos são redundantes [5].

Importância para o projeto: CBA não deve ser avaliado isoladamente. CMAR e CPAR são referências conceituais, enquanto árvore de decisão, regressão logística e Random Forest podem atuar como baselines preditivos. O capítulo também justifica seleção de regras por poder discriminativo, não somente por frequência.

4 Síntese comparativa

Table 1: Contribuições dos textos e implicações para o PIBIC.

Trabalho	Contribuição principal	Questão deixada para o projeto
Liu et al. (1998)	CBA-RG, CBA-CB e CARs; classificador por lista ordenada de regras.	Como reproduzir fielmente o baseline e controlar a explosão de regras?
Wang et al. (1998)	Fusão de intervalos numéricos orientada pela interessância.	Quanto a discretização altera desempenho, regras e estabilidade?
Molina e Prados-Suárez (2023)	Busca guiada por complexidade e interessância.	É possível reduzir regras sem perda relevante de desempenho?
Ndour et al. (2015)	Padrões para classe rara e métricas sensíveis ao desbalanceamento.	O método preserva sensibilidade e precisão para a classe minoritária?
Han et al. (2012)	Relação entre CBA, CMAR, CPAR e padrões discriminativos.	A regra de maior precedência é melhor que combinar múltiplas regras?

Da síntese surgem cinco gargalos: (1) número combinatório de candidatos; (2) escolha de suporte e confiança; (3) discretização; (4) ordenação e resolução de conflitos entre regras; e (5) avaliação inadequada em classes desbalanceadas. Para um PIBIC inicial, tentar resolver simultaneamente os cinco problemas diluiria a contribuição. O recorte deve produzir um baseline sólido e investigar um eixo principal.

5 Próximo passo recomendado

5.1 Pergunta de pesquisa

Recomenda-se adotar a seguinte pergunta:

Uma seleção multicritério de regras, guiada por qualidade preditiva, interessância e simplicidade, consegue reduzir a complexidade do CBA sem perda estatisticamente relevante de desempenho?

Essa pergunta conecta diretamente o CBA clássico ao trabalho contemporâneo de Molina e Prados-Suárez, incorpora o alerta do livro sobre padrões discriminativos e permite incluir discretização e desbalanceamento como fatores experimentais, sem transformar cada um deles em uma contribuição independente.

5.2 Hipóteses

H1 – redução de complexidade:

uma ordenação multicritério reduz o número de regras e o comprimento médio dos antecedentes em relação ao CBA clássico.

H2 – não inferioridade preditiva:

a versão proposta mantém desempenho comparável ao CBA, dentro de uma margem de não inferioridade previamente definida.

H3 – estabilidade:

regras escolhidas pela versão proposta apresentam maior recorrência entre partições de validação cruzada.

H4 – classe minoritária:

quando houver desbalanceamento, a redução de regras não compromete de forma desproporcional o recall e a PR-AUC da classe minoritária.

5.3 Extensão proposta: CBA-QS

Como nome provisório, sugere-se **CBA-QS** (CBA guiado por Qualidade e Simplicidade). Após gerar CARs válidas, cada regra r recebe um escore normalizado:

$$S(r) = w_1 \tilde{Q}(r) + w_2 \tilde{I}(r) + w_3 \tilde{C}(r) - w_4 \tilde{L}(r),$$

em que Q representa qualidade preditiva (por exemplo, confiança corrigida ou fator de certeza), I representa interessância (por exemplo, *lift* ou risco relativo), C representa cobertura e L é o comprimento do antecedente. Os pesos w_i devem ser definidos apenas com os dados de treinamento interno. Uma alternativa mais interpretável é usar ordenação lexicográfica ou fronteira de Pareto, evitando condensar objetivos diferentes em um único número.

A primeira versão não deve alterar o gerador do CBA. Ela deve modificar apenas a ordenação/seleção, pois isso permite atribuir diferenças experimentais a um componente bem definido. Somente depois de validada essa versão deve-se antecipar a poda durante a geração para obter ganho computacional.

6 Plano de progressão do PIBIC

6.1 Fase 1 – domínio conceitual e baseline (meses 1–2)

1. Implementar ou adaptar um pipeline reprodutível contendo discretização, codificação transacional, geração de CARs, ordenação, cobertura e classe padrão.
2. Criar testes unitários com uma base artificial pequena, na qual suporte, confiança, precedência e predição possam ser calculados manualmente.

3. Reproduzir o comportamento do CBA em três bases públicas pequenas: uma binária balanceada, uma multiclasse e uma binária desbalanceada.
4. Registrar semente, partições, versão de dependências, tempo, memória e quantidade de regras em todas as execuções.

Marco de conclusão: o aluno consegue explicar e verificar uma predição desde o registro de entrada até a regra acionada e a classe padrão.

6.2 Fase 2 – estudo controlado do CBA (meses 3–4)

Executar validação cruzada estratificada aninhada, ou validação cruzada estratificada repetida se o custo for alto. Comparar:

- suporte mínimo em grade logarítmica compatível com o tamanho das bases;
- confiança mínima;
- comprimento máximo do antecedente;
- sem discretização adicional, discretização por quantis e discretização supervisionada;
- CBA sem poda e com poda.

O objetivo não é escolher parâmetros usando o conjunto de teste, mas produzir curvas que relacionem desempenho, número de candidatos, número de regras finais e tempo.

Marco de conclusão: relatório experimental que identifica quais fatores dominam o desempenho e a complexidade.

6.3 Fase 3 – desenvolvimento do CBA-QS (meses 5–7)

1. Implementar métricas de interesse candidatas: *lift*, *leverage*, fator de certeza e risco relativo.
2. Introduzir penalização explícita pelo tamanho da regra e poda de redundância entre antecedentes aninhados.
3. Comparar score ponderado, ordenação lexicográfica e seleção de Pareto.
4. Fazer estudo de ablação: remover um termo por vez para descobrir qual componente explica o resultado.

Marco de conclusão: versão proposta definida, congelada e acompanhada de pseudocódigo, testes e justificativa dos critérios.

6.4 Fase 4 – avaliação comparativa (meses 8–10)

Comparar CBA clássico, CBA-QS e, se houver implementação confiável, CMAR ou CPAR. Incluir como referências uma árvore de decisão e um modelo preditivo forte apropriado aos dados. A comparação deve usar as mesmas divisões e o mesmo pré-processamento interno a cada dobra.

Além das métricas preditivas, reportar:

- número de regras candidatas e finais;
- comprimento médio e máximo dos antecedentes;
- cobertura do classificador e uso da classe padrão;
- tempo de treinamento e inferência e pico de memória;
- estabilidade das regras entre dobras, por similaridade de Jaccard;
- exemplos de decisões corretas e erros explicados pelas regras acionadas.

6.5 Fase 5 – consolidação (meses 11–12)

Realizar análise estatística, organizar repositório reprodutível, redigir relatório final e preparar artigo ou resumo expandido. Caso os resultados do CBA-QS sejam negativos, o estudo ainda terá valor se demonstrar, com protocolo adequado, quando medidas de interesse não superam a ordenação clássica.

7 Protocolo experimental recomendado

7.1 Bases e recorte inicial

Começar com quatro a seis bases tabulares públicas, evitando dezenas de bases antes de estabilizar o código. O conjunto deve variar em número de amostras, atributos, classes, proporção minoritária e presença de atributos numéricos. Depois, incluir uma base do domínio principal do grupo, se disponível e documentada.

7.2 Métricas

Para classificação binária, utilizar balanced accuracy, precisão, recall, F_1 , MCC, ROC-AUC e PR-AUC. Em forte desbalanceamento, priorizar PR-AUC, recall e MCC; acurácia deve aparecer apenas como medida complementar. Para multiclasse, usar versões macro de precisão, recall e F_1 .

Para interpretabilidade, não basta contar regras. Devem ser avaliados número de regras, comprimento dos antecedentes, redundância, cobertura e estabilidade. Uma boa versão do CBA deve ser simultaneamente preditiva, pequena e estável.

7.3 Validação e estatística

Toda discretização e escolha de hiperparâmetros deve ocorrer dentro das dobras de treinamento para evitar vazamento. Recomenda-se validação cruzada estratificada repetida. As diferenças entre métodos devem ser analisadas de forma pareada nas mesmas dobras, com intervalos de confiança. Em múltiplas bases, pode-se usar teste de Friedman seguido de comparação pós-hoc; com poucas bases, intervalos por base e tamanhos de efeito são mais informativos que uma alegação geral baseada apenas em p -valor.

7.4 Critério de sucesso

Antes dos experimentos finais, definir uma margem de não inferioridade preditiva, por exemplo uma queda máxima pequena em balanced accuracy ou macro- F_1 . O CBA-QS será considerado útil se reduzir substancialmente o número/comprimento de regras e permanecer dentro dessa margem. A margem exata deve ser justificada pelo domínio e não escolhida após observar os resultados.

8 Riscos e controles

Table 2: Principais riscos do projeto e ações de controle.

Risco	Controle recomendado
Explosão de candidatos	Limitar comprimento, aplicar poda, registrar memória e começar com bases pequenas.
Vazamento na discretização	Ajustar discretizador exclusivamente no treino de cada dobra.
Otimização sobre o teste	Separar seleção interna de hiperparâmetros e avaliação externa.
Alta confiança para classe comum	Incluir medidas corrigidas pela prevalência e métricas de desbalanceamento.
Regras instáveis	Medir recorrência/Jaccard entre dobras e analisar regras equivalentes.
Escopo excessivo	Fixar uma contribuição principal: seleção por qualidade e simplicidade.
Comparação injusta	Usar as mesmas partições e relatar orçamento computacional de cada método.

9 Entregáveis esperados

1. Repositório com pipeline, testes, configuração e instruções de reprodução.
2. Implementação validada do CBA clássico.
3. Relatório do estudo de sensibilidade de discretização e limiares.
4. Implementação do CBA-QS e estudo de ablação.
5. Tabelas e gráficos de desempenho, complexidade, custo e estabilidade.
6. Relatório PIBIC e manuscrito curto com pergunta, método, resultados e limitações.

10 Conclusão

Os textos mostram que o valor do CBA está na união entre poder preditivo e regras compreensíveis, mas também que sua fragilidade central é gerar e ordenar um conjunto potencialmente enorme de padrões. Para João Fábio, o caminho mais consistente é começar pela reprodução rigorosa do CBA e evoluir para uma seleção de regras orientada por qualidade e simplicidade. Essa progressão oferece aprendizagem técnica, resultados intermediários verificáveis e uma contribuição científica delimitada.

O tratamento de atributos numéricos deve fazer parte do desenho experimental, e o desbalanceamento deve determinar as métricas e, se necessário, uma extensão posterior. CMAR, CPAR e PBBC são referências importantes, mas não devem ser implementados todos no início. O primeiro resultado científico deve responder com evidência se é possível obter um classificador associativo menor e mais estável sem sacrificar desempenho relevante.

References

- [1] B. Liu, W. Hsu e Y. Ma. Integrating classification and association rule mining. In *Proceedings of KDD-98*, pp. 80–86, 1998.
- [2] K. Wang, S. H. W. Tay e B. Liu. Interestingness-based interval merger for numeric association rules. In *Proceedings of KDD-98*, pp. 121–128, 1998.
- [3] C. Molina e B. Prados-Suárez. Classification based on association rules: Complexity and interestingness guided algorithm. In *2023 3rd International Conference on Electrical, Computer, Communications and Mechatronics Engineering (ICECCME)*, 2023. DOI: [10.1109/ICECCME57830.2023.10253036](https://doi.org/10.1109/ICECCME57830.2023.10253036).
- [4] C. Ndour, A. Diop e S. Dossou Gbété. Classification approach based on association rules mining for unbalanced data. arXiv:1202.5514v2, 2015.
- [5] J. Han, M. Kamber e J. Pei. *Data Mining: Concepts and Techniques*. 3rd ed., Morgan Kaufmann, 2012. Seções sobre mineração de padrões frequentes e classificação associativa.